UNICAMP

Instituto de Matemática, Estatística e Computação Científica da Universidade Estadual de Campinas (IMECC)

Eduardo Saegi de Souza Hsu - RA:277142,
Joaquim Bertoldi Nucci - RA:277177,
Marcel Hideki Sousa Adati - RA:242910

Estimação de preços de veículos

Campinas – 2025

Sumário

1.Introdução e motivação.....3
2.Metodologia.....3
3.Resultados.....5
4.Conclusão.....11
5. Referências.....12

1.Introdução e motivação

A precificação de veículos usados é um tema de grande relevância econômica e social, tanto para consumidores quanto para empresas do setor automotivo. O mercado de carros seminovos e usados é altamente dinâmico, sendo influenciado por diversos fatores, como ano de fabricação, marca, modelo, tipo de combustível, quilometragem percorrida e características adicionais do veículo. Entender como essas variáveis se relacionam com o preço final de venda é essencial para a tomada de decisões mais informadas, sejam elas de compra, venda ou avaliação de valor de mercado.

O trabalho tem como objetivo estimar o preço de veículos usados a partir de suas características técnicas e de uso, utilizando modelos de regressão linear. A variável resposta (Y) será o preço do veículo, enquanto as demais variáveis disponíveis na base de dados atuarão como preditoras, permitindo investigar quais atributos exercem maior influência sobre o valor final.

A escolha desse tema se justifica pela sua aplicabilidade prática e pela riqueza de análises estatísticas que podem ser realizadas. A modelagem do preço de carros é um exemplo clássico de problema de predição em que os conceitos de regressão múltipla, diagnóstico de modelo e validação de pressupostos podem ser aplicados de forma integrada. Além disso, a base de dados utilizada, obtida de repositórios públicos, oferece um conjunto realista e heterogêneo de observações, o que torna a investigação mais desafiadora e representativa de um cenário real de análise de dados.

2.Metodologia

O estudo baseou-se em um conjunto de dados contendo 2.060 observações referentes a características comerciais e técnicas de automóveis. A variável resposta definida para o estudo foi o preço do veículo. As variáveis explicativas originais incluíam: marca, modelo, quilometragem, tipo de combustível, transmissão, local de venda, cor, histórico de propriedade (número de donos), tipo de vendedor, tração, cilindradas, potência (cavalos), torque máximo, ano de lançamento, capacidade do tanque, capacidade de assentos, e as dimensões do veículo (altura, comprimento e largura).

A etapa inicial consistiu na limpeza da base de dados. Foram removidas as observações que apresentavam dados faltantes (*missing values*), resultando em uma amostra final de 1.959 observações válidas.

Para reduzir a dimensionalidade e melhorar a interpretabilidade do modelo, realizou-se o reagrupamento de variáveis categóricas que apresentavam um número excessivo de níveis. As transformações incluíram:

- **Marca e Modelo:** Agrupados em categorias de mercado (ex: luxo, off-road, popular) e tipo de carroceria (ex: hatchback, sedan, SUV).
- **Localização:** As diversas cidades foram binarizadas em dois grupos: metrópoles e não-metrópoles.
- **Cores:** Classificadas em grupos cromáticos (tons terrosos, neutros, vibrantes, etc.).
- **Temporalidade:** A variável "ano de lançamento" foi convertida para "idade do veículo", visando capturar melhor a depreciação.

A análise exploratória foi conduzida em duas frentes. Para as 10 variáveis contínuas, utilizou-se uma matriz de correlação e gráficos de dispersão para identificar a força e a direção das associações lineares. Para as 9 variáveis categóricas, o impacto sobre a variável resposta (preço) foi avaliado visualmente através de boxplots, permitindo a observação de diferenças nas medianas e na variabilidade entre os grupos.

A seleção de variáveis preditoras priorizou aquelas com maior correlação com o preço. Durante este processo, identificou-se a presença de multicolinearidade entre diversas variáveis explicativas. Para mitigar esse problema inicialmente, optou-se por manter apenas a variável com maior correlação com a resposta dentre aquelas que apresentavam alta correlação entre si.

O processo de modelagem seguiu uma abordagem iterativa:

1. **Modelo Inicial (LM):** O primeiro modelo de Regressão Linear Múltipla revelou-se inadequado devido à sensibilidade a *outliers*, prejudicando a normalidade dos resíduos.
2. **Regressão Robusta:** Como alternativa, ajustou-se um modelo robusto, que apresentou melhor aderência aos dados reais ao minimizar o impacto de valores discrepantes.
3. **Refinamento do Modelo Linear:** Retornando à regressão linear múltipla, buscou-se uma especificação que capturasse as não-linearidades observadas. Foram aplicadas transformações como a escala logarítmica na variável resposta, termos quadráticos para quilometragem e idade, e um termo de interação entre idade e carros de luxo.

Para garantir a generalização dos resultados e evitar o overfitting, todos os modelos propostos foram submetidos à validação cruzada. A escolha da especificação definitiva baseou-se nas métricas de desempenho obtidas nesse processo, especificamente o R^2-ajustado, o Erro Absoluto Médio (MAE) e a Raiz do Erro Quadrático Médio (RMSE).

Adicionalmente, a adequação dos modelos foi verificada por meio de diagnósticos gráficos detalhados. Utilizou-se o gráfico de quantil-quantil para avaliar a suposição de normalidade dos resíduos, o gráfico de Valores Preditos vs. Valores

Reais para analisar a aderência do ajuste aos dados observados e o gráfico de Resíduos Padronizados x Valores Preditos, para validação de suposições de homocedasticidade. Por fim, calculou-se o Fator de Inflação de Variância (VIF) do modelo final, confirmando que a multicolinearidade foi devidamente controlada.

3.Resultados

A análise dos dados revelou um mercado de veículos usados altamente heterogêneo, em que diferentes características técnicas e comerciais influenciam o preço de forma significativa. Os resultados são apresentados a seguir, combinando a exploração inicial, o ajuste dos modelos e a comparação preditiva entre as abordagens avaliadas.

A investigação começou pela análise das variáveis categóricas. No caso da localização, veículos vendidos em metrópoles apresentam preços medianos um pouco maiores do que os vendidos em outras regiões. Entre os combustíveis, observou-se que híbridos concentram os preços mais elevados, seguidos pelos veículos diesel e elétricos. A transmissão automática também apresenta mediana superior à manual. Nas categorias de marca e modelo, nota-se forte dispersão, mas com destaque para os veículos de marcas voltadas para o luxo e alto desempenho, e para modelos conversíveis e coupe, que aparecem consistentemente entre os mais caros. Além disso, veículos com menos proprietários anteriores, vendidos por concessionárias, e aqueles com tração 4×4 tendem a apresentar medianas ligeiramente superiores.

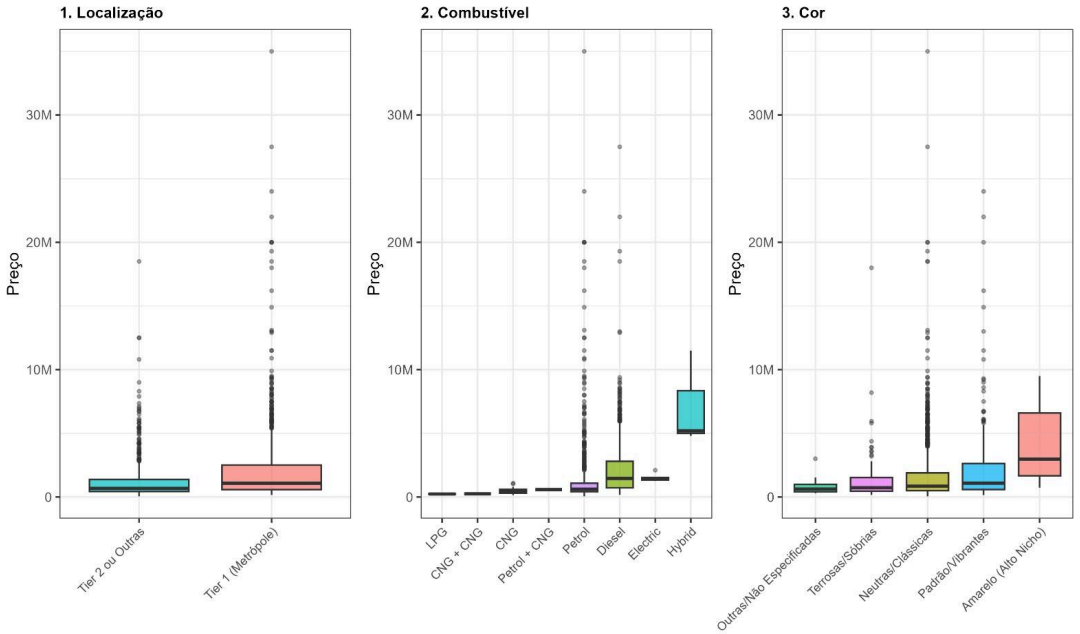


Figura 1: *Boxplot:* Preço por categorias (Localização, Combustível e Cor)

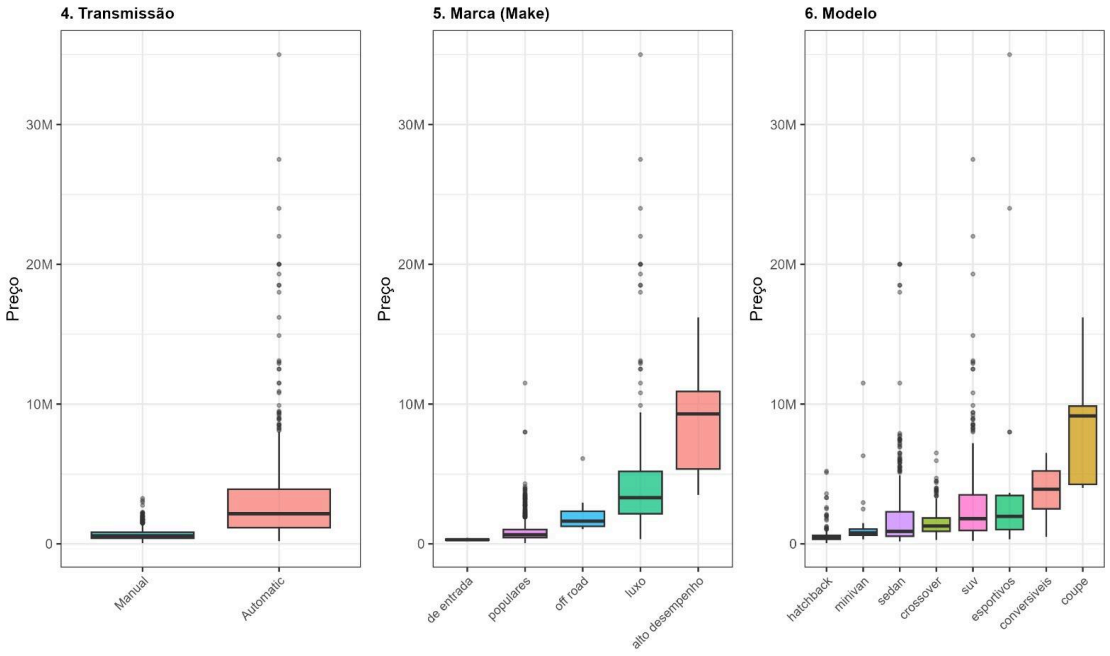


Figura 2: *Boxplot:* Preço por categorias (Transmissão, Marca e Modelo)

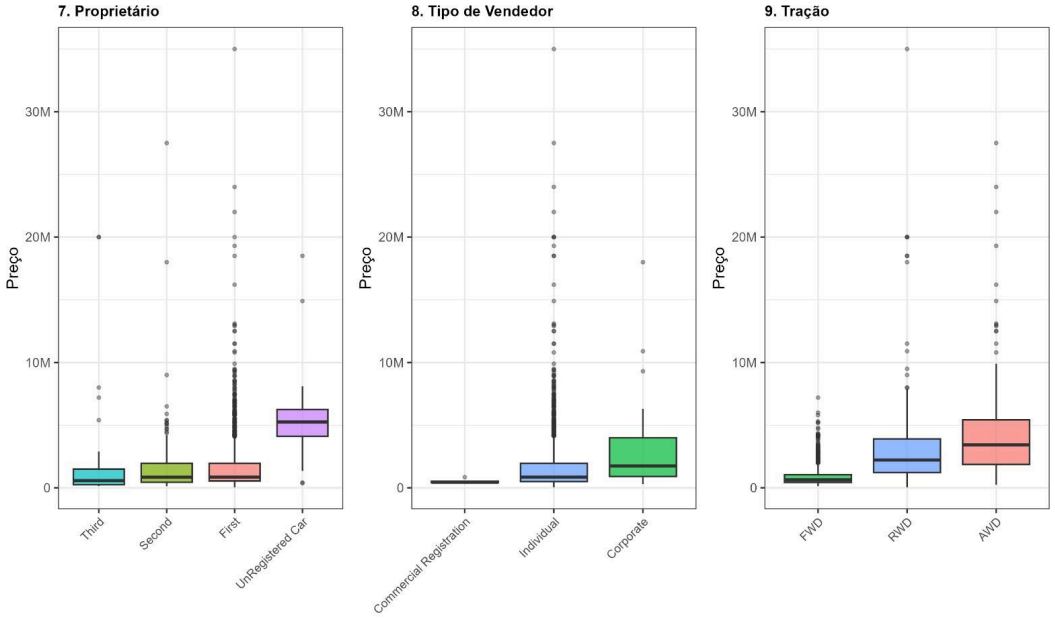


Figura 3: *Boxplot:* Preço por categorias (Proprietário, Tipo de Vendedor e Tração)

No conjunto das variáveis contínuas, a matriz de correlação evidenciou relações fortes e coerentes com o preço. A potência máxima, capacidade do tanque e dimensões do veículo correlacionam-se positivamente com o valor, enquanto a idade e a quilometragem são negativamente correlacionadas, padrão consistente com a depreciação natural. A matriz de dispersão complementou essa leitura ao

revelar não linearidades importantes, especialmente em idade e quilometragem, além de um conjunto de outliers que poderia comprometer os modelos lineares tradicionais.

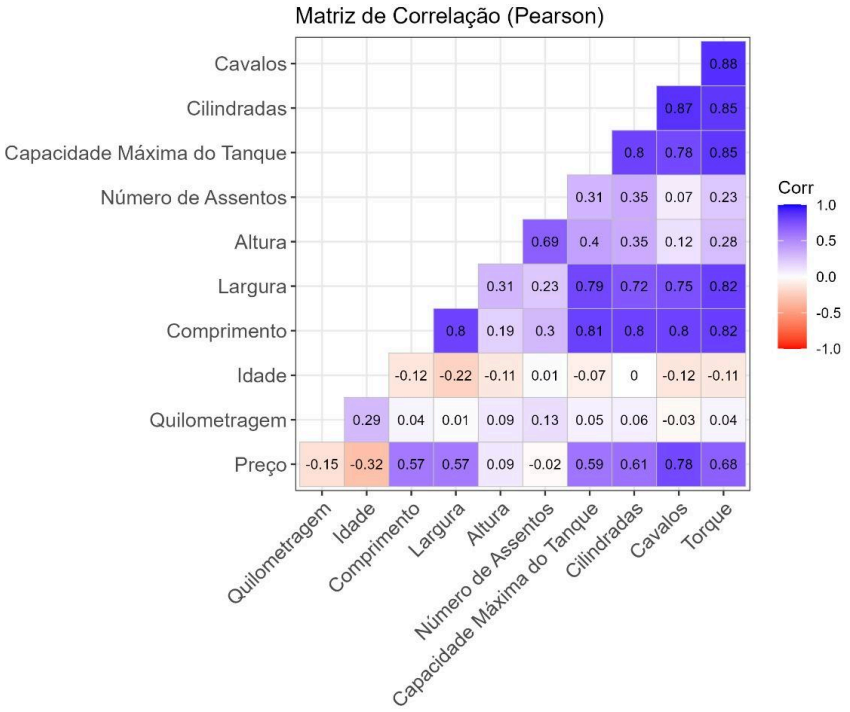


Figura 4: Matriz de Correlação (Pearson)

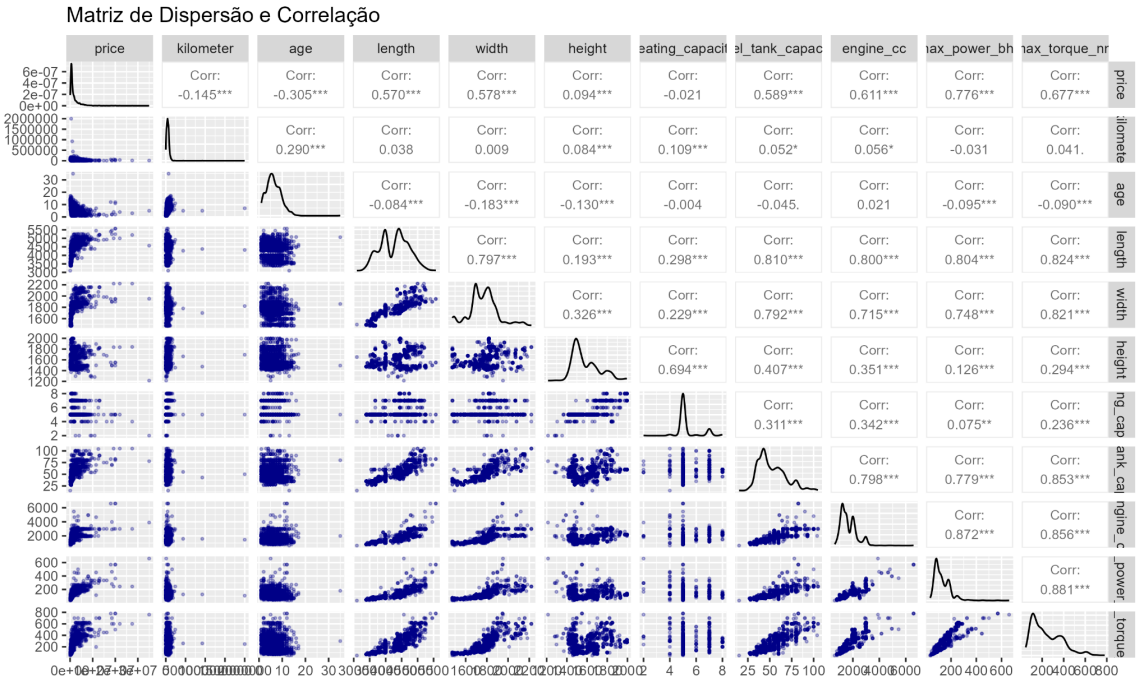


Figura 5: Matriz de Dispersão e Correlação

Os modelos lineares ajustados inicialmente apresentaram comportamento geral adequado, mas os gráficos diagnósticos revelaram aspectos importantes sobre sua estrutura. Também foi ajustado um modelo robusto com o objetivo de mitigar o impacto dos outliers. O QQ-plot indicou que os resíduos não seguiam uma normal estrita, apresentando caudas mais pesadas compatíveis com uma t-Student, sugerindo influência de outliers. O gráfico de resíduos versus valores ajustados mostrou ausência de padrão sistemático, mas a presença de variância crescente para preços mais altos indicou heterocedasticidade moderada. Apesar dessas imperfeições, o gráfico de valores preditos vs observados exibiu ótima aderência, refletindo boa capacidade de capturar a relação central entre as variáveis.

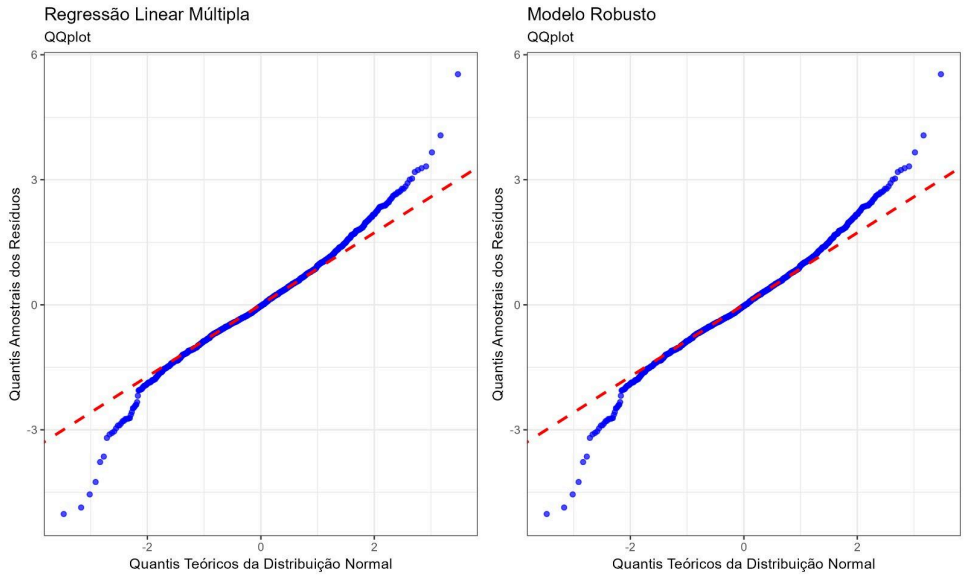


Figura 6: QQ–Plot do Resíduos (Regressão Linear múltipla e Modelo Robusto)

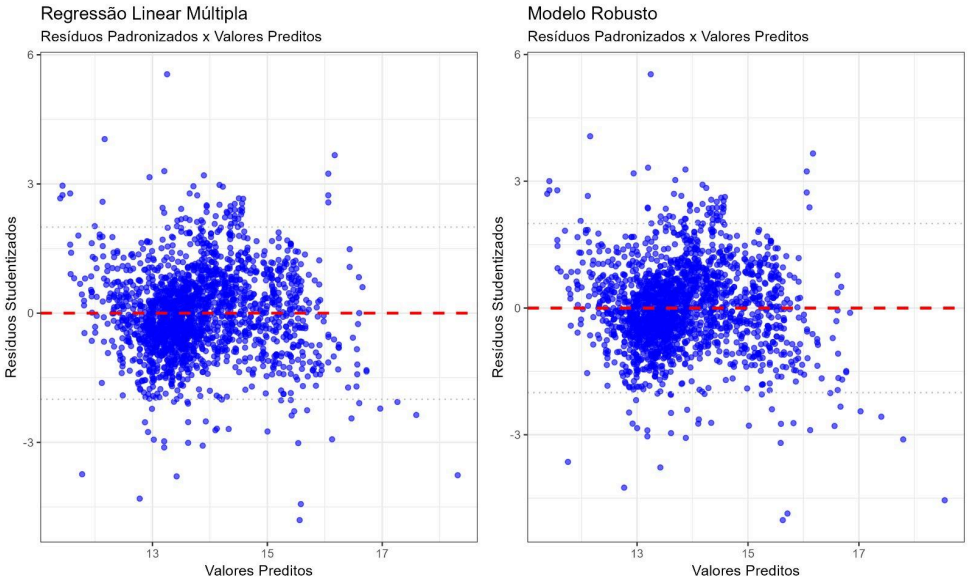


Figura 7: Gráficos Resíduos X Valores Preditos (Regressão Linear múltipla e Modelo Robusto)

A partir desses padrões, buscou-se melhorar a estabilidade dos resíduos. As caudas pesadas observadas no QQ-plot motivaram a aplicação de transformações: utilizou-se a escala logarítmica no preço, foram incluídos termos quadráticos para idade e quilometragem e adicionou-se um termo de interação entre idade e categoria de luxo, já que os gráficos exploratórios indicavam padrões distintos de depreciação entre veículos premium e não premium. Essas escolhas melhoraram substancialmente a normalidade dos resíduos e suavizaram a heterocedasticidade observada.

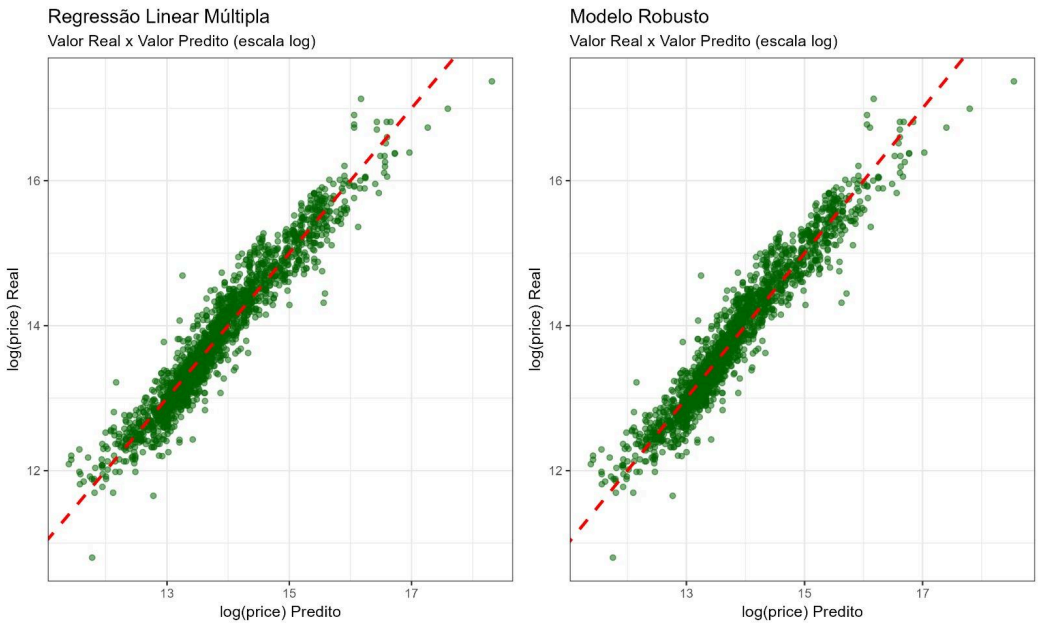


Figura 7: Gráficos Resíduos X Valores Preditos (Regressão Linear múltipla e Modelo Robusto)

O modelo robusto reduziu a influência das observações extremas, mas na prática apresentou resultados muito semelhantes ao modelo linear transformado, tanto nos gráficos diagnósticos quanto nas métricas de desempenho. Isso indica que a combinação de log-transformação, termos quadráticos e interação já havia resolvido a maior parte dos problemas estruturais.

Os resultados numéricos dos modelos de Regressão Linear Múltipla (LM), Regressão Robusta (RLM) e Regressão Quantílica (RQ) estão reunidos na Tabela 1, que apresenta os coeficientes estimados. Observa-se coerência entre os métodos, com variações pontuais esperadas devido às diferentes funções de perda. A Tabela 2, por sua vez, mostra os valores de GVIF, que permanecem dentro de faixas aceitáveis, descartando multicolinearidade problemática após as transformações aplicadas.

Tabela 1: Resultados da Regressão (Coeficientes estimados)

Termo	LM (MQO)	RLM (Robusto)	RQ (Mediana)
(Intercepto)	11,50	11,50	11,30
Potência máxima em cv	0,00665	0,00715	0,00743
Marca de entrada	-1,32	-1,25	-1,19
Marca de luxo	0,0829	0,0634	0,0213
Marca off road	-0,692	-0,651	-0,631
Marca de populares	-0,0744	-0,0685	-0,0609
Largura	0,0144	0,0135	0,0144
Câmbio manual	-0,0207	-0,0184	-0,0162
Idade^2	$-7{,}001 \times 10^{-3}$	$-7{,}006 \times 10^{-3}$	$-7{,}0072 \times 10^{-3}$
Km^2	$-1{,}28 \times 10^{-10}$	$-1{,}29 \times 10^{-10}$	$-1{,}39 \times 10^{-10}$
Idade * Marca de luxo	-0,0633	-0,0632	-0,0666

Tabela 2: Fator de Inflação da Variância(VIF)

Variável	GVIF	Df	GVIF$^{1/(2\cdot Df)}$
Potência máxima em cv	3,223917	1	1,795527
Marca do carro	6,231513	4	1,256968
Largura	2,490620	1	1,578170
Câmbio	1,926805	1	1,388094
Idade^2	1,369862	1	1,170411
Km^2	1,002225	1	1,001112
Idade * Marca de luxo	4,966966	1	2,228669

Para avaliar a capacidade de generalização dos modelos, utilizou-se validação cruzada com 10 folds, incluindo também o modelo Random Forest (RF), além dos outros três já citados. O conjunto foi dividido em dez partes; em cada iteração, nove foram usadas para ajuste e uma para teste. Dessa forma, cada observação teve seu preço previsto exatamente na rodada em que ficou fora do treinamento. As métricas obtidas estão resumidas na Tabela 3.

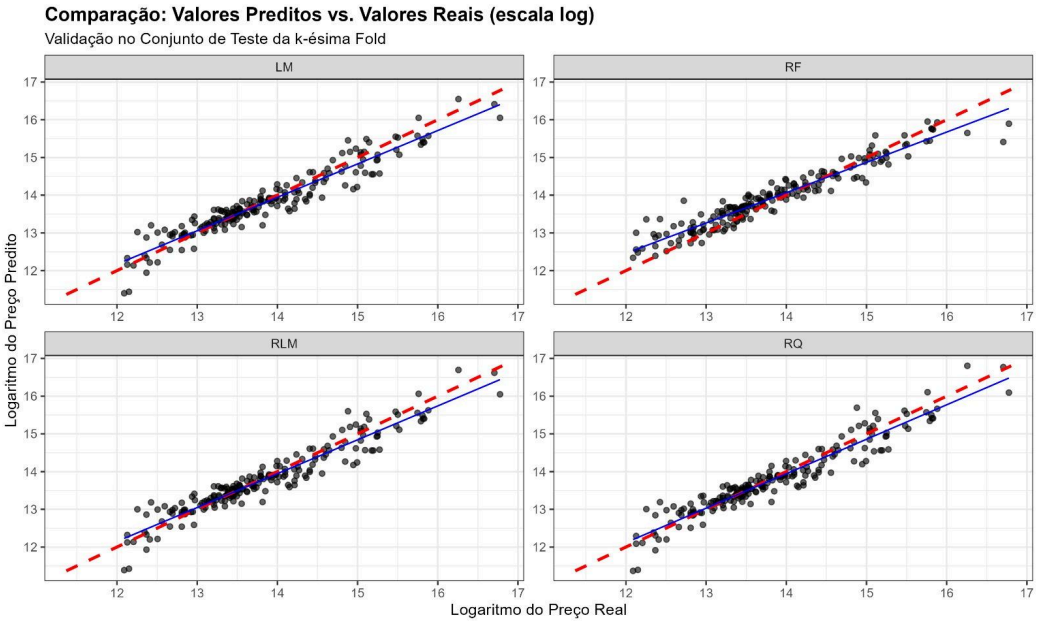


Figura 7: Gráficos da Validação Cruzada com 10 folds comparando os modelos

Tabela 2: Comparação de Desempenho dos Modelos de regressão

Modelo	RMSE	MAE	Rsq
LM	0.2639124	0.2022737	0.9262140
RLM	0.2638139	0.2008263	0.9263563
RQ	0.2658624	0.2004809	0.9257118
RF	0.2617463	0.1927378	0.9388011

Os modelos LM e RLM apresentaram erros bastante próximos, confirmando que a transformação logarítmica e os termos adicionais foram eficazes. O Random Forest obteve o melhor desempenho preditivo, com menor RMSE e MAE, refletindo sua flexibilidade, mas com menor interpretabilidade.

Os gráficos do modelo Random Forest comprovam isso. Já que, conforme indicado pelo gráfico de dispersão onde os valores previstos estão muito alinhados com os valores reais (próximos à linha de identidade y=x), sugerindo um baixo erro geral. Contudo, o gráfico de resíduos padronizados revela um vício sistemático (tendência não-linear) e potencial heterocedasticidade: a linha de tendência dos resíduos não é plana em zero, indicando que o modelo tende a superestimar preços baixos e subestimar preços muito altos

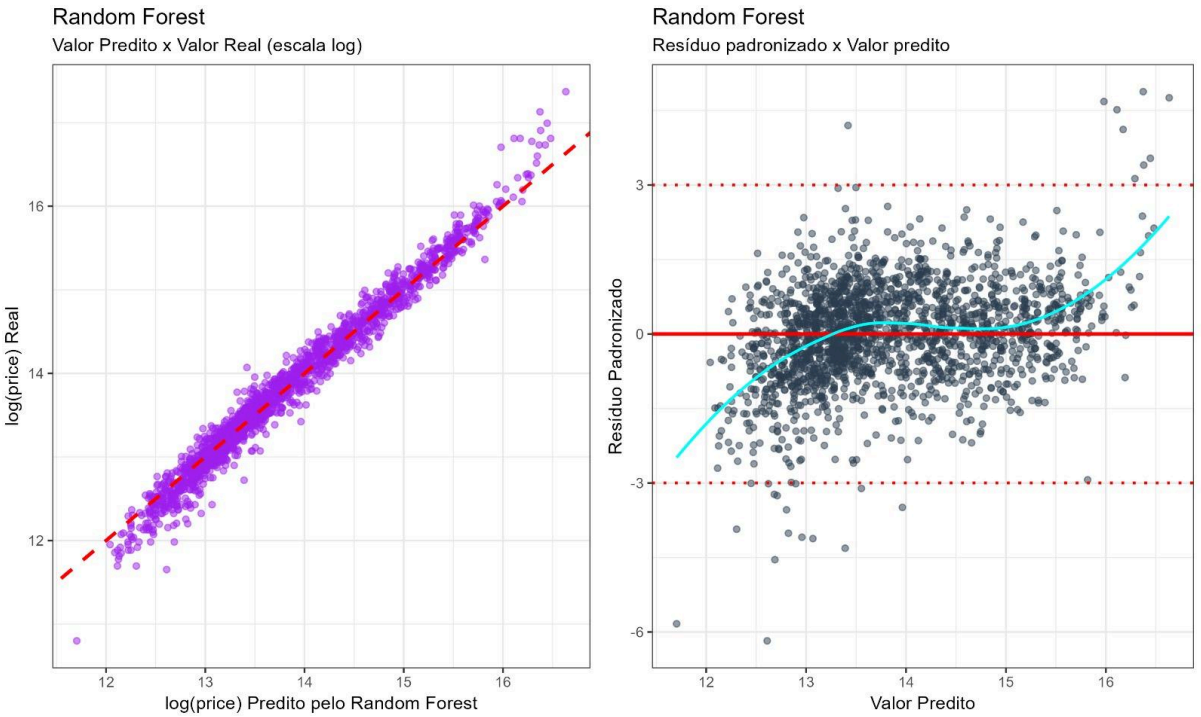


Figura 8: Gráficos Modelo Random Forest

A comparação final indicou que, embora o modelo Random Forest apresente a melhor capacidade preditiva, os modelos lineares transformados mantêm excelente desempenho com a vantagem adicional de interpretabilidade.

4.Conclusão

Com base na análise comparativa das métricas de desempenho, conclui-se que o modelo Random Forest apresentou a maior capacidade preditiva, sendo, portanto, a escolha ideal para cenários onde a precisão da previsão é a prioridade absoluta. No entanto, observou-se que o modelo de Regressão Linear Múltipla obteve métricas de erro e R^2 quase idênticas às dos demais modelos testados, mantendo a vantagem da parcimônia. Dessa forma, caso o objetivo principal da análise se desloque da predição pura para a interpretação da influência individual de cada preditor, a Regressão Linear Múltipla demonstra-se a alternativa mais robusta, oferecendo um equilíbrio eficiente entre simplicidade e desempenho.

Apesar dos resultados consistentes, o estudo apresenta algumas limitações que devem ser consideradas. A presença de outliers e a distribuição residual com caudas mais pesadas, semelhante a uma t-Student, indicam que, mesmo após transformações, parte da variabilidade extrema não foi completamente capturada. Além disso, algumas variáveis categóricas possuem grande dispersão interna, o que pode mascarar diferenças reais entre grupos. Outro ponto a considerar é que o

estudo utilizou apenas um recorte estático de dados, sem explorar sazonalidade, tendências temporais ou efeitos de mercado dinâmicos.

Para trabalhos futuros, várias melhorias podem ser consideradas. Uma delas é testar outros tipos modelos que lidem melhor com resíduos que apresentam caudas mais pesadas e leve heterocedasticidade, como observado neste estudo, para verificar se alguma abordagem alternativa oferece melhor equilíbrio entre desempenho e interpretabilidade. Por fim, estudos com dados de períodos diferentes ou acompanhando o mercado ao longo do tempo poderiam ampliar a compreensão sobre como esses fatores evoluem.

5. Referências

POSIT TEAM. **RStudio**: Integrated Development Environment for R. Boston, MA: Posit Software, PBC, 2025. Disponível em: **http://www.posit.co/**. Acesso em: **5 nov. 2025**.

Wickham, H., Averick, M., Bryan, J., Chang, W., D'Agostino McGowan, L., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., ... Yutani, H. (2019). Welcome to the Tidyverse. *Journal of Open Source Software*, *4*(43), 1686. https://doi.org/10.21105/joss.01686

Kassambara, A. (2023). *ggcorrplot: Visualization of a Correlation Matrix using 'ggplot2'*. R package version 0.1.4.

McLeod, A. I., & Xu, C. (2020). *bestglm: Best Subset GLM and Regression Utilities*. R package version 0.37.3.

Venables, W. N., & Ripley, B. D. (2002). *Modern Applied Statistics with S*. Fourth Edition. Springer, New York. ISBN 0-387-95457-0.

Firke, S. (2023). *janitor: Simple Tools for Examining and Cleaning Dirty Data*. R package version 2.2.0.

Arnold, J. B. (2024). *ggthemes: Extra Themes, Scales and Geoms for 'ggplot2'*. R package version 5.1.0.

Kaplan, J. (2020). *fastDummies: Fast Creation of Dummy (Binary) Columns and Rows from Categorical Variables*. R package version 1.7.3.

Koenker, R. (2023). *quantreg: Quantile Regression*. R package version 5.97.

Liaw, A., & Wiener, M. (2002). Classification and Regression by randomForest. *R News*, 2(3), 18-22.

Wickham, H., & Seidel, D. (2023). *scales: Scale Functions for Visualization*. R package version 1.3.0.

Schloerke, B., Cook, D., Larmarange, J., Briatte, F., Marbach, M., Thoen, E., Elberg, A., & Crowley, J. (2025). *GGally: Extension to 'ggplot2'*. R package version 2.4.0. Disponível em: https://ggobi.github.io/ggally/.

Kaggle Dataset: Birla, N. (2020). *Vehicle dataset*. Kaggle. Disponível em: https://www.kaggle.com/datasets/nehalbirla/vehicle-dataset-from-cardekho. Acesso em: 20 nov. 2025.

Slides de Aula: Benaglia, T. (2024). *Análise de Regressão: Slides de aula*. Disciplina ME613. Instituto de Matemática, Estatística e Computação Científica (IMECC), Universidade Estadual de Campinas (UNICAMP). Disponível via Moodle.